

Aplicação de RAG em Cenários Reais

Residência em Tecnologia. Trilha de IA Generativa e RAG. AULA_06

Observação sobre a entrega

Este documento apresenta dois cenários completos, das Partes 1 a 6, cada um com a arquitetura final. O Cenário 1 trata de um assistente de direitos para imigrantes na Espanha. O Cenário 2 trata de um assistente de consulta a diretrizes clínicas na UTI. Ao final estão a comparação entre os dois, as referências e fontes de dados.

Cenário 1. Assistente de navegação de direitos para imigrantes e refugiados na Espanha

Parte 1. Identificação do problema

1.1 Descrição do problema

Qual é o problema que você deseja resolver?

A falta de acesso à informação jurídica por imigrantes, refugiados e menores desacompanhados na Espanha. O direito existe em lei, mas está escrito em espanhol jurídico e espalhado em várias fontes. A pessoa que mais precisa da informação costuma ser a que menos consegue entendê-la. O objetivo é reduzir a distância entre o direito previsto em lei e o passo prático que a pessoa precisa dar, na língua dela e com base na norma vigente.

Quem utilizaria a aplicação?

O usuário principal é o imigrante ou o menor desacompanhado, com pouco ou nenhum domínio do espanhol, pouco conhecimento jurídico e pouca familiaridade com tecnologia, que usa apenas aplicativos de mensagem e voz. O usuário secundário é o profissional que o atende, como assistente social de centro de acolhimento, voluntário de ONG ou estagiário de defensoria.

Que tipo de informação o usuário gostaria de consultar?

- Elegibilidade para a regularização de 2026 e prazos vigentes.
- Passos e documentos para solicitar proteção internacional (asilo) e o cartão vermelho.
- Protocolos de transferência de menores (reforma do Artigo 35) e prazos legais, como o limite de 15 dias.
- Direitos imediatos garantidos por lei, como saúde, acolhimento, matrícula escolar e proteção contra devolução.

De onde vêm essas informações?

De um corpus jurídico oficial e atualizado do Estado espanhol, que inclui a Ley de Extranjería, a reforma do Artigo 35 (2025), o decreto da regularização extraordinária de 2026, normativas do Ministerio de Inclusión, Seguridad Social y Migraciones e os protocolos oficiais das Comunidades Autônomas.

Por que utilizar um LLM sozinho não seria suficiente?

O procedimento é oficial, específico e muda com frequência. Um LLM puro não tem acesso garantido à norma mais recente e pode responder pela regra antiga. A resposta também precisa citar a fonte oficial exata, o que um LLM sozinho não faz.

Como o usuário vai utilizar o sistema?

Para imigrantes e menores, uma interface web leve para celular, com entrada e saída por voz e tradução, ou integração com aplicativos de mensagem como WhatsApp e Telegram. Para mediadores e profissionais, uma interface web de consulta e uma API REST integrada aos sistemas de gestão das ONGs e dos centros de acolhimento.

Três perguntas reais que um usuário faria

- Cheguei na Espanha sem meus pais e estou em Ceuta, tenho direito de ir para outra cidade mais calma?
- Cheguei na Espanha em 2025 e não tenho papéis, posso me regularizar com essa nova lei de 2026?
- O que acontece se a polícia me parar enquanto estou esperando a resposta do meu pedido de asilo?

1.2 Por que RAG

Por que RAG é adequado para esse problema?

A resposta precisa vir de uma norma oficial vigente e ser citável. Três traços do problema pedem RAG: a informação é oficial e muda, o erro custa um direito e a fonte precisa ser rastreável. RAG recupera o trecho da norma vigente e gera a resposta presa a ele, com a fonte citada. O ajuste fino não serve, pois retira a rastreabilidade e exige treinar o modelo de novo a cada mudança de lei.

Que tipo de conhecimento precisa ser fornecido ao modelo?

O corpus jurídico oficial espanhol descrito na seção anterior, incluindo os protocolos das Comunidades Autônomas, que aplicam o procedimento de forma diferente em cada região.

Esse conhecimento muda com que frequência?

Em ritmo médio e por saltos de alto impacto. A base é estável, mas sofre alterações pontuais que trocam a resposta inteira, como a reforma de 2025 e a regularização de 2026. Em momentos de crise, protocolos podem entrar em poucas semanas.

Existe necessidade de documentos privados ou da organização?

O núcleo é público. O que exige documento próprio é o conhecimento operacional local, como o funcionamento de cada centro de acolhimento e as cartilhas internas das ONGs. Esse conhecimento não é publicado de forma estruturada.

Que problemas ocorreriam com o conhecimento pré-treinado? Exemplo concreto.

Desatualização e invenção. Exemplo: à pergunta sobre regularizar-se em 2026 tendo chegado em 2025, um LLM puro tende a responder que não existe via geral de regularização e que seria preciso arraigo social após três anos de residência. Essa resposta é a regra antiga e ignora a regularização de 2026 e seus critérios. O resultado prático é que alguém que se qualifica desiste de pedir.

1.3 Limitações. Quando RAG não é a resposta

RAG não é a melhor solução quando a resposta é um fato exato, estruturado ou calculável, e não a interpretação de um texto. Para prazo exato, contagem, status de processo ou verificação de elegibilidade, uma consulta exata é melhor do que recuperar texto e deixar o modelo inferir.

- **Busca por palavra-chave.** Boa para o profissional que sabe o termo técnico e quer chegar ao documento. Não serve para o leigo, que não conhece o termo jurídico. Serve como camada complementar.

- **Banco estruturado e SQL.** Certo para fatos discretos, como prazos, requisitos objetivos e endereços de centros. Não interpreta a lei nem explica o porquê.
- **Regras determinísticas.** Certas para elegibilidade objetiva, que é uma árvore de decisão, como data de chegada, tempo de residência e ausência de antecedentes. Mais confiável do que pedir ao modelo para julgar.
- **API direta.** Necessária para dado dinâmico e externo, como status do pedido de asilo e vagas em centros. Esse dado não está em documento nenhum.
- **Combinação com RAG.** É a solução real. Um roteador de intenção classifica a pergunta e a envia para a ferramenta certa: regras para elegibilidade, SQL para prazo e contagem, API para status e RAG para o que a lei diz. O LLM entra no fim para traduzir a resposta para a língua do usuário.

Pergunta que RAG responde mal e um banco relacional responde bem

Quantos dias eu ainda tenho para pedir a transferência do meu filho antes do prazo do Artigo 35? Isso é uma conta com data, e não interpretação de texto. RAG recupera o trecho que diz 15 dias, mas errar a conta é fácil e não é auditável. Um banco relacional guarda a data de início do caso e o limite legal e responde com uma consulta exata.

Se a pergunta exigisse contar, somar ou ordenar

RAG recupera apenas os k trechos mais relevantes, não a base inteira. Para perguntas como quantos centros estão acima da capacidade ou ordenar as Comunidades por vaga disponível, o modelo não vê todos os documentos ao mesmo tempo e estima o resto. Agregação exige varredura estruturada da base, que é tarefa de SQL.

Parte 2. Organização dos documentos

Tipos de arquivo

PDF para leis, decretos, normativas e protocolos, sendo parte nativa e parte escaneada. HTML para portais oficiais e páginas das Comunidades Autônomas. DOCX para cartilhas das ONGs. Planilhas em CSV ou XLSX com dados estruturados, como prazos e endereços, que alimentam a camada SQL e não a base vetorial. Áudio e vídeo não entram como fonte, e a voz do usuário é transcrita na entrada.

Volume, tamanho e frequência

O volume é de centenas de documentos, pois o núcleo jurídico é finito e o que aumenta a base são os protocolos das 17 Comunidades Autônomas e as cartilhas das ONGs. O tamanho é heterogêneo: uma lei consolidada tem dezenas a centenas de páginas, um protocolo local ou cartilha tem 2 a 10 páginas e uma página web tem poucos KB. A entrada de documentos é baixa em ritmo normal e sobe em crise. Documentos antigos não são apagados, e sim substituídos por nova versão e arquivados como histórico.

Organização de pastas proposta

```
documentos/
├── nacional/
│   ├── leis_base/
│   ├── asilo/
│   ├── regularizacao_2026/
│   └── menores_art35/
├── comunidades_autonomas/
│   ├── ceuta/
│   ├── canarias/
│   └── madri/
├── ong_parceiras/
└── _arquivo_historico/
```

└─ _quarentena/

A divisão genérica por tipo de documento não serve aqui. Os dois filtros que importam são a jurisdição, ou seja, nacional ou qual Comunidade Autônoma, e o tema, como asilo, regularização e menores. A pasta por jurisdição vira filtro na recuperação e evita responder com o protocolo de outra região. A pasta por tema segue a forma como o usuário pensa a informação. Separar a fonte oficial das cartilhas de ONG permite dar precedência à norma oficial.

Documento que não deve entrar na base

Não devem entrar: dado pessoal ou caso individual, versão revogada e fonte não oficial. Para impedir a entrada, existe um pipeline de ingestão com etapa de validação, representada pela pasta de quarentena. Todo documento novo passa por verificação de fonte oficial, varredura de dado pessoal e marcação de vigência antes de ser indexado.

Como lidar com versões

Por vigência como metadado e substituição versionada. Cada chunk carrega o status de vigência e as datas. A recuperação filtra por documentos vigentes. Quando sai norma nova, a versão antiga é marcada como revogada, movida para o arquivo histórico e a nova é indexada como vigente. Assim, a versão de 2024 existe para consulta histórica, mas não é recuperada como resposta atual.

Parte 3. Pipeline de ingestão

3.1 Extração

A extração é roteada por tipo de arquivo e preserva a proveniência, ou seja, o arquivo, a pasta e a URL, para permitir a citação.

- **PDF com texto selecionável.** Extração direta com Docling para Markdown, que preserva a hierarquia de título, artigo e apartado, necessária para citar.
- **PDF escaneado.** OCR antes da extração. É o caminho mais frágil e pode produzir texto errado, como um número de artigo trocado.
- **Tabelas.** Devem ser mantidas, pois uma tabela achatada perde a relação entre linha e coluna. A tabela com dado estruturado é enviada para a camada SQL.
- **Imagens.** Descarta-se decoração e logotipo. Mantém-se fluxograma de procedimento, com descrição, e imagem que contém texto, com OCR.
- **Multimodais.** A voz do usuário é transcrita na entrada. Um vídeo de ONG, se necessário, é transcrito e tratado como texto de menor autoridade, nunca como norma.

Problemas já enfrentados nas atividades anteriores. Na AULA_04, a estratégia de dividir por seção gerou um chunk de mais de 52 mil caracteres que estourou o limite da API. No `extrair.py`, o LLM devolvia o JSON dentro de uma cerca de markdown, que precisava ser removida antes do parse. Observou-se também que, quando o Docling usa quebra de linha simples, a divisão por linha e por parágrafo produz o mesmo resultado.

3.2 Limpeza e normalização

Precisam ser removidos: cabeçalho e rodapé repetidos, numeração de página, boilerplate de HTML como aviso de cookies e menu, sumário de leis longas e marca d'água. A marca d'água de rascunho indica um documento que não deve entrar como vigente. Precisam ser padronizados: a codificação em UTF-8, pois o espanhol quebra com ñ e acentos fora de UTF-8, as formas Unicode de acentuação, as quebras de linha e o espaçamento, e a forma de citar o artigo, unificando Art. 35 e Artículo 35 em uma forma única. O risco de limpar demais é fundir dois artigos, apagar a marcação de apartado e perder a granularidade de citação,

descartar uma nota de rodapé jurídica e perder uma tabela. A regra é limpar o ruído com firmeza e preservar a estrutura jurídica.

3.3 Frequência de ingestão

O pipeline é híbrido. Há uma carga inicial em lote de todo o corpus, um job agendado semanal que varre o BOE e os portais oficiais em busca de norma nova, e ingestão sob demanda em momentos de crise. Quando um documento é atualizado, reprocessa-se apenas ele. O sistema guarda um hash do conteúdo de cada documento. Documento novo é ingerido, documento com hash diferente é reproprocessado, com aplicação do versionamento, e documento inalterado não é tocado.

Parte 4. Metadados

4.1 Schema do documento

```
{
  "document_id": "es-nac-reg2026-001",
  "title": "Real Decreto de regularización 2026",
  "source": "BOE núm. 90, 14/04/2026",
  "url_origem": "https://www.boe.es/...",
  "jurisdicao": "nacional",
  "comunidade_autonoma": null,
  "tema": "regularizacao_2026",
  "tipo_norma": "decreto",
  "autoridade": "oficial",
  "idioma": "es",
  "status_vigencia": "vigente",
  "data_vigencia_inicio": "2026-04-14",
  "data_vigencia_fim": null,
  "hash_conteudo": "sha256:9f2a...",
  "ingerido_em": "2026-08-17"
}
```

4.2 Schema do chunk

```
{
  "chunk_id": "es-nac-reg2026-001-0007",
  "document_id": "es-nac-reg2026-001",
  "text": "Podrán acogerse las personas que acrediten...",
  "referencia_legal": "Artículo 3, apartado 1",
  "pagina": 4,
  "jurisdicao": "nacional",
  "tema": "regularizacao_2026",
  "status_vigencia": "vigente",
  "fonte": "BOE núm. 90, 14/04/2026",
  "url_origem": "https://www.boe.es/..."
}
```

Justificativa dos campos. O document_id e o hash dão identidade e permitem a detecção de mudança para o reproprocessamento incremental. A source e a url_origem servem para a citação. A jurisdicao e a comunidade_autonoma são o filtro que evita misturar regiões. O tema serve de filtro e segue como o usuário pensa. O tipo_norma e a autoridade definem a precedência entre norma oficial e cartilha. O idioma deixa a língua explícita. O status_vigencia e as datas são o filtro central que evita responder pela norma revogada. No chunk, a referencia_legal e a pagina localizam o trecho e aparecem na citação.

Metadados para filtrar e exemplo

Usaria status_vigencia, jurisdicao ou comunidade_autonoma e tema. O filtro é indispensável na pergunta sobre transferência de menor em Ceuta, pois sem o filtro de

comunidade_autonoma o sistema pode recuperar o protocolo de outra região. Toda pergunta sobre a regra atual depende do filtro de status_vigencia igual a vigente.

Metadados para citar e o que aparece na tela

Usaria fonte, referencia_legal, url_origem e data_vigencia_inicio. Junto da resposta apareceria, por exemplo: Fonte, Real Decreto de regularização de 2026, Artículo 3.1, BOE núm. 90, 14/04/2026, com link para o documento oficial.

Metadado caro de acrescentar depois

Qualquer campo derivado por LLM ou do layout original, como a referencia_legal ou a pagina. Acrescentá-lo depois obriga a reprocessar e a gerar embeddings de toda a base de novo, e se o documento original mudou, alguns campos ficam irrecuperáveis.

Como extrair esses metadados

De forma mista. Jurisdicao, tema e tipo_norma vêm da estrutura de pastas. Datas, hash e página vêm de regra. A referencia_legal e o título vêm do LLM com saída estruturada em JSON schema, com remoção da cerca de markdown.

Parte 5. Chunking

Estratégia e parâmetros

A estratégia é um recursive splitter consciente da estrutura jurídica, ancorado na fronteira de artigo e apartado, usando o MarkdownHeaderTextSplitter sobre o Markdown do Docling. A regra principal é não cortar um artigo ao meio. O tamanho é de 500 a 800 tokens, buscando um artigo ou apartado por chunk. O overlap é de 10 a 15 por cento, cerca de 50 a 100 tokens, para cobrir a fronteira entre chunks. A divisão é por seção primeiro, com recuo para parágrafo e sentença quando a seção é grande. O splitter é recursivo. A estratégia varia por tipo de documento: lei por artigo, protocolo e cartilha por seção ou passo e HTML por bloco. Um contrato e uma transcrição de call center não pedem o mesmo tratamento, pois o contrato tem estrutura a preservar e a transcrição é fala corrida dividida por turno.

Chunks pequenos, chunks grandes, tabela e imagem

Chunks muito pequenos perdem contexto, e o trecho recuperado vem sem o entorno que dá sentido. Chunks muito grandes estouram a janela do modelo de embedding, como visto na AULA_04 com o chunk de 52 mil caracteres, e misturam assuntos, o que dilui a similaridade. Uma tabela é tratada como unidade atômica e não é cortada, e se contém dado estruturado vai para SQL. Um fluxograma cortado não significa nada, então mantém-se inteiro com descrição ou descarta-se se for decorativo.

Como saber se o chunking foi bom

Por avaliação de recuperação, como no RELATORIO.md da AULA_04. Monta-se um conjunto de perguntas reais com a fonte correta esperada e mede-se a taxa de acerto no top-k. As evidências a reunir são: nenhum chunk excede a janela do embedding, um artigo conhecido é recuperável inteiro e a estratégia por artigo supera a de tamanho fixo no conjunto de teste.

Parte 6. Embeddings

Item	Resposta
Modelo escolhido	BGE-M3 (BAAI/bge-m3)
Dimensão do embedding	1024

Suporta português?	Sim
É multilíngue?	Sim, mais de 100 idiomas
Tamanho máximo de entrada	8192 tokens
É open source?	Sim
Pode ser executado localmente?	Sim, cerca de 550 milhões de parâmetros, roda em uma GPU
Possui API?	Sim, por provedores terceiros
Custo aproximado	Gratuito para uso local, apenas custo de computação
Fonte	Chen et al. 2024 (BAAI); model card HuggingFace BAAI/bge-m3

Por que esse modelo é adequado ao cenário

O BGE-M3 atende aos três pontos críticos do cenário. Ele é multilíngue e cross-lingual, ou seja, aproxima uma pergunta feita em árabe, francês ou português do texto oficial em espanhol, o que é o centro do caso de uso. Ele aceita entradas de até 8192 tokens, o que resolve a limitação do paraphrase-multilingual-MiniLM, cuja janela curta fazia o modelo processar apenas o começo dos chunks grandes. E ele tem uso comprovado em busca jurídica e funciona como recuperador em pipelines RAG com índice FAISS, ferramenta já empregada em atividades anteriores do curso.

Modelo alternativo considerado e descartado

Foram considerados dois. O paraphrase-multilingual-MiniLM-L12-v2, descartado como solução final pela janela curta e pela qualidade mais fraca em línguas como árabe e dari, servindo apenas como MVP. E o multilingual-e5-large, forte, mas sem o contexto longo e igualado ou superado pelo BGE-M3 em RAG multilíngue.

Sigilo muda a escolha entre local e API?

Sim. O dado do usuário é sensível, pois envolve migrante, possivelmente indocumentado e possivelmente menor. Enviar esse texto para uma API externa de embedding é risco de proteção de dados. Rodar o BGE-M3 localmente mantém o dado dentro da própria infraestrutura, e o modelo aberto permite esse controle.

Relação entre a janela máxima e o chunking

A janela do embedding é o teto do tamanho útil do chunk. Com o MiniLM, de 128 tokens, os chunks precisavam ser pequenos ou perdiam informação. Com o BGE-M3, de 8192 tokens, é possível usar o artigo inteiro. Por isso, escolher o embedding e escolher o chunking são a mesma decisão.

Arquitetura final. Cenário 1

Diagrama do sistema (código Mermaid, renderizável em mermaid.live)

```

graph TD
    subgraph INGESTAO
        A[Documentos oficiais PDF HTML DOCX] --> B[Roteador por tipo]
        B -->|PDF nativo| C[Docling para Markdown]
        B -->|PDF escaneado| D[OCR e Docling]
        B -->|HTML| E[Extraí conteúdo, remove navegacao]
        C --> F[Limpeza e normalizacao]
        D --> F
        E --> F
        F --> G[Metadados: pasta e LLM em JSON]
        G --> H[Chunking consciente de artigo]
        H --> I[Embeddings BGE-M3 local]
    end

```

```

I --> J[(Banco vetorial FAISS com filtro de metadado)]
end
subgraph CONSULTA
K[Usuario voz ou texto] --> Lx[Transcricao e deteccion de idioma]
Lx --> M{Roteador de intencao}
M --> |status do processo| N[API oficial]
M --> |prazo, quantos, onde| O[SQL]
M --> |elegibilidade| Pr[Regras deterministicas]
M --> |o que a lei diz| Q[Recuperacao RAG filtro vigente e jurisdicao]
Q --> J
N --> R[LLM: resposta ancorada, traduz e cita fonte]
O --> R
Pr --> R
Q --> R
R --> S[Resposta com citacao e encaminhamento a ONG humana]
end

```

Tabela de decisões

Etapa	Decisão	Justificativa em uma linha
Extração	Docling para Markdown, roteado por tipo, OCR para escaneado	Preserva a hierarquia de artigo, necessária para citar
Limpeza	Firme no ruído, conservadora na estrutura jurídica	Apagar cabeçalho é seguro, fundir artigos gera resposta errada
Chunking	Recursive por artigo, 500 a 800 tokens, overlap de 10 a 15 por cento	Não cortar a norma ao meio e caber na janela do embedding
Metadados	Pasta (determinístico) e LLM em JSON, com vigência e jurisdição	São os filtros que evitam norma revogada e região errada
Embeddings	BGE-M3 local, 1024 dimensões, 8192 tokens	Multilíngue com contexto longo e privacidade do dado

Riscos e limitações da proposta

- Qualidade em línguas de baixo recurso. Árabe dialetal, dari e algumas línguas africanas podem ter recuperação mais fraca, e esse é o público mais vulnerável.
- OCR de escaneado ruim. Um número de artigo trocado pelo OCR entra na base como se fosse correto. O pipeline reduz, mas não elimina o risco.
- Conhecimento operacional local desatualizado. Endereços, dias de atendimento e protocolos locais mudam sem virar norma publicada e a base pode ficar defasada.
- Agregação e cálculo. RAG não conta, soma nem ordena, e depende da camada SQL, o que faz do roteador de intenção um ponto sensível.
- Não substitui aconselhamento jurídico. Casos complexos exigem um profissional, e o guardrail reduz, mas não anula, o risco de excesso de confiança de quem é vulnerável.

Cenário 2. Assistente de consulta a diretrizes clínicas na UTI

Parte 1. Identificação do problema

1.1 Descrição do problema

Qual é o problema que você deseja resolver?

A conduta correta para um caso grave na UTI, como a escolha do antibiótico empírico, o ajuste de dose por função renal e o reconhecimento de critérios de sepse, está definida em diretrizes e protocolos. Esse conhecimento está espalhado em documentos longos, como

diretrizes de sociedades médicas, consensos e protocolos internos do hospital. Durante o plantão, sob pressão de tempo, o médico não consegue folhear um documento de dezenas de páginas para localizar a recomendação exata e a dose certa. O objetivo é reduzir o tempo entre a dúvida clínica e a recomendação baseada em diretriz, com a fonte citada, sem depender de memória.

Quem utilizaria a aplicação?

O usuário principal é o médico intensivista ou o residente de medicina intensiva de plantão. Tem alto conhecimento clínico, mas não é usuário técnico de TI. Usa o sistema à beira do leito ou no posto de enfermagem, muitas vezes de madrugada, com o paciente na frente e uma decisão a tomar em minutos. O usuário secundário é o farmacêutico clínico, que confere dose e interação.

Que tipo de informação o usuário gostaria de consultar?

- Antibioticoterapia empírica para um perfil de paciente.
- Ajuste de dose por clearance renal.
- Critérios diagnósticos de sepse e choque séptico, e quando escalar ou desescalar.
- Contraindicações e interações medicamentosas.

De onde vêm essas informações?

De um corpus clínico oficial, formado por diretrizes de sociedades médicas, como AMIB, IDSA/ATS e Surviving Sepsis Campaign, por consensos, por uma base de medicamentos para dose e interação, e pelos protocolos internos do hospital, que têm precedência local.

Por que utilizar um LLM sozinho não seria suficiente?

Por três motivos ligados à segurança do paciente. A alucinação é perigosa, pois um LLM puro pode inventar uma dose, uma droga ou um critério. A rastreabilidade é obrigatória, pois o médico precisa ver de qual diretriz e seção veio a recomendação para assumir a responsabilidade. E o conhecimento local e atualizado, como o protocolo do hospital e a diretriz mais recente, não está no treino do modelo, e o protocolo interno é privado.

Como o usuário vai utilizar o sistema?

Por uma interface web ou aplicativo responsivo, que funciona no tablet do posto e no celular, com a resposta sempre acompanhada do trecho da fonte citada. Não há uso de dado de sensor em tempo real. Um requisito de projeto é que a resposta seja de apoio à decisão, com aviso de que a decisão e a prescrição são do médico, e o sistema não emite ordem médica autônoma.

Três perguntas reais que um usuário faria

- Paciente com pneumonia grave, 68 anos, creatinina 2,4 e alergia a penicilina, qual esquema empírico eu começo e em que dose?
- Esse paciente está com lactato 3,1 e pressão arterial média 62 mesmo após o volume, pela diretriz isso fecha choque séptico e devo iniciar vasopressor?
- O protocolo daqui do hospital para pneumonia grave diverge em algo do que a diretriz recomenda para esse caso?

1.2 Por que RAG

Por que RAG é adequado para esse problema?

A resposta precisa vir de uma diretriz verificável e citável, e não da memória do modelo. Três traços pedem RAG: a fonte importa tanto quanto a resposta, o erro afeta a segurança do paciente e o conhecimento local do hospital precisa entrar. RAG recupera o trecho da diretriz

e gera a resposta presa a ele, com a citação. O ajuste fino não serve, pois apaga a rastreabilidade e exige treinar de novo a cada diretriz nova.

Que tipo de conhecimento precisa ser fornecido ao modelo?

As diretrizes de sociedades, os protocolos clínicos, a base de medicamentos para dose e ajuste por função renal, e os protocolos internos do hospital, que têm precedência local sobre a diretriz geral.

Esse conhecimento muda com que frequência?

Com frequência baixa, por saltos de alto impacto. Uma diretriz pode ficar estável por anos e então uma atualização muda a conduta de primeira linha de uma vez. O sistema não precisa reindexar todo dia, mas precisa de um processo para marcar a versão quando sai diretriz nova.

Existe necessidade de documentos privados ou da organização?

Sim, e é decisivo. O protocolo interno do hospital é privado e muitas vezes diverge da diretriz nacional, por perfil de resistência bacteriana local ou por recursos disponíveis. Sem ele, o sistema dá a resposta de livro, que pode estar errada para aquele hospital.

Que problemas ocorreriam com o conhecimento pré-treinado? Exemplo concreto.

Alucinação com aparência de autoridade. Exemplo: perguntado sobre antibiótico empírico para pneumonia grave em paciente com clearance renal baixo, um LLM puro pode responder levofloxacino 750 mg por via intravenosa uma vez ao dia, que é a dose padrão, sem ajustar para a função renal, quando o correto seria reduzir a dose ou o intervalo. A frase é plausível e está errada, e a dose não ajustada gera toxicidade. Perguntado pela fonte, o modelo inventa uma diretriz.

1.3 Limitações. Quando RAG não é a resposta

RAG não é a melhor solução quando a resposta é um cálculo, um valor de referência exato ou uma verificação de critério objetivo, e não a interpretação de um texto. Cálculo de dose por peso e função renal, escores clínicos como SOFA, qSOFA e SAPS-3, e valores de referência laboratoriais são melhor resolvidos por fórmula ou tabela do que por recuperação de texto.

- **Busca por palavra-chave.** Útil para o médico que sabe o termo técnico e quer chegar ao trecho da diretriz. Não lida bem com a pergunta descritiva sobre um perfil de paciente. Serve como camada complementar.
- **Banco estruturado e SQL.** Certo para valores de referência, faixas de dose padrão por medicamento e dados objetivos. Não interpreta a diretriz nem explica o raciocínio.
- **Regras determinísticas.** Certas para cálculo de escore e de dose. Um escore como o qSOFA é uma soma de critérios objetivos, e uma regra é mais confiável e auditável do que um modelo inferindo.
- **API direta.** Necessária para o dado do paciente em tempo real, como resultado de exame e sinais vitais vindos do prontuário eletrônico. Esse dado não está em documento.
- **Combinação com RAG.** É a solução. Um roteador de intenção envia cálculo de escore e de dose para regra, valores de referência para SQL, dado do paciente para a API do prontuário, e conduta baseada em diretriz para RAG. O LLM organiza a resposta final e cita a fonte.

Pergunta que RAG responde mal e um banco relacional responde bem

Qual a dose máxima diária de vancomicina para um adulto? É um valor de referência exato. RAG pode recuperar um trecho e o modelo pode arredondar ou misturar faixas de duas

fontes. Um banco relacional guarda a faixa de dose padrão por medicamento e responde com um valor exato e auditável, o que em dose é obrigatório.

Se a pergunta exigisse contar, somar ou ordenar

RAG recupera apenas os k trechos mais relevantes, não o corpus inteiro. Para perguntas como quantas diretrizes recomendam esse antibiótico como primeira linha ou ordenar os antibióticos por espectro, o modelo não vê todas as diretrizes ao mesmo tempo e estima o resto. Agregação exige varredura estruturada da base, que é tarefa de SQL.

Parte 2. Organização dos documentos

Tipos de arquivo

O PDF é o formato dominante, pois diretrizes e consensos são publicados assim, em geral em PDF nativo de boa qualidade. Há HTML de portais de sociedades médicas e de bases de medicamentos, DOCX de protocolos internos do hospital e planilhas com tabelas de dose e valores de referência, que alimentam a camada SQL. Não há áudio nem vídeo como fonte.

Volume, tamanho e frequência

O volume é baixo, de dezenas a poucas centenas de documentos, pois o conjunto de diretrizes relevantes para a UTI é limitado. O tamanho é heterogêneo: uma diretriz completa tem dezenas a mais de cem páginas e um protocolo interno tem poucas páginas. A entrada de documentos é rara e ligada à publicação de nova diretriz ou à revisão de protocolo. Documentos antigos são substituídos por nova versão e arquivados.

Organização de pastas proposta

```
documentos/  
├── diretrizes_sociedades/  
│   ├── sepsis/  
│   ├── pneumonia/  
│   └── antibioticoterapia/  
├── protocolos_internos/  
│   └── hospital_x/  
├── medicamentos/  
├── _arquivo_historico/  
└── _quarentena/
```

Os dois eixos que importam são o tema clínico, como sepsis, pneumonia e antibioticoterapia, que é a forma como o médico pensa a informação, e a proveniência, ou seja, diretriz de sociedade ou protocolo interno, que define a precedência. Separar o protocolo interno da diretriz permite dar prioridade ao protocolo local quando os dois divergem, que é uma regra clínica importante. Uma divisão por tipo de arquivo não refletiria nem o pensamento do médico nem o filtro de precedência.

Documento que não deve entrar na base

Não devem entrar dado de paciente, versão revogada de diretriz e material não validado, como resumo de terceiros sem fonte. Para impedir a entrada, existe um pipeline com etapa de validação, a pasta de quarentena, que verifica a fonte, remove qualquer dado de paciente e marca a vigência antes de indexar.

Como lidar com versões

Por vigência como metadado e substituição versionada. Cada chunk carrega o status de vigência, e a recuperação filtra por vigente. Quando sai diretriz nova, a antiga é marcada como revogada, movida para o histórico e a nova é indexada. Assim, uma recomendação de conduta antiga não é recuperada como atual, o que na UTI evita uma conduta desatualizada.

Parte 3. Pipeline de ingestão

3.1 Extração

A extração é roteada por tipo de arquivo e preserva a proveniência para permitir a citação.

- **PDF com texto selecionável.** Extração direta com Docling para Markdown, preservando a estrutura de seções e recomendações da diretriz, necessária para citar.
- **PDF escaneado.** Menos comum aqui, pois diretrizes costumam ser nativas, mas um protocolo interno antigo pode ser escaneado e exigir OCR.
- **Tabelas.** São críticas neste cenário e devem ser mantidas com cuidado, pois muitas doses e critérios estão em tabela. Uma tabela de dose achatada perde a relação entre medicamento, faixa e ajuste. A tabela de dose é enviada para a camada SQL.
- **Imagens.** Fluxogramas de conduta, como o algoritmo de sepse, carregam informação real e devem ser mantidos com descrição. Figuras ilustrativas são descartadas.
- **Multimodais.** Não há áudio nem vídeo como fonte. O conteúdo é texto e tabela.

Problemas que podem surgir. Um chunk de diretriz longo pode estourar o limite do modelo de embedding, como observado em atividade anterior do curso, na AULA_04. Uma tabela de dose mal extraída pode trocar um valor, o que é grave. A extração precisa preservar a estrutura de recomendação para não juntar duas condutas distintas.

3.2 Limpeza e normalização

Precisam ser removidos cabeçalho e rodapé repetidos, numeração de página, sumário da diretriz e a lista de referências bibliográficas ao final, que não é conduta. Precisam ser padronizados a codificação em UTF-8, a acentuação e a forma de escrever dose e unidade, como mg, mg/kg e mg/dia. O risco de limpar demais é remover uma nota de rodapé que traz uma ressalva de dose, fundir duas recomendações ou destruir uma tabela de dose. A regra é preservar dose, unidade e a estrutura de recomendação.

3.3 Frequência de ingestão

O pipeline é híbrido. Há uma carga inicial em lote de todas as diretrizes e protocolos, uma verificação agendada, porém mais espaçada do que no cenário de imigração, pois diretriz nova é rara, o que torna uma checagem mensal suficiente, e ingestão sob demanda quando o hospital revisa um protocolo interno. Reprocessa-se apenas o documento alterado, detectado por hash, com aplicação do versionamento.

Parte 4. Metadados

4.1 Schema do documento

```
{
  "document_id": "ssc-sepse-2021-001",
  "title": "Surviving Sepsis Campaign 2021",
  "source": "Intensive Care Medicine, 2021",
  "url_origem": "https://...",
  "tema": "sepse",
  "proveniencia": "diretriz_sociedade",
  "sociedade": "SSC",
  "precedencia": "geral",
  "idioma": "en",
  "status_vigencia": "vigente",
  "data_vigencia_inicio": "2021-10-01",
  "data_vigencia_fim": null,
  "hash_conteudo": "sha256:..."
}
```

4.2 Schema do chunk

```
{
  "chunk_id": "ssc-sepse-2021-001-0012",
  "document_id": "ssc-sepse-2021-001",
  "text": "Recomenda-se iniciar vasopressor para manter PAM...",
  "secao": "Vasopressores",
  "recomendacao_ref": "Recomendação 4.2",
  "pagina": 12,
  "tema": "sepse",
  "proveniencia": "diretriz_sociedade",
  "precedencia": "geral",
  "status_vigencia": "vigente",
  "fonte": "Surviving Sepsis Campaign 2021",
  "url_origem": "https://..."
}
```

Justificativa dos campos. O `document_id` e o hash dão identidade e permitem a detecção de mudança. A `source` e a `url_origem` servem para a citação. O `tema` serve de filtro e segue como o médico pensa. A `proveniencia` e a `precedencia` definem a prioridade do protocolo interno sobre a diretriz geral, que é uma regra clínica central. A `sociedade` identifica a autoridade da fonte. O `status_vigencia` e as datas evitam recuperar uma conduta revogada. No `chunk`, a `secao`, a `recomendacao_ref` e a `pagina` localizam o trecho e aparecem na citação.

Metadados para filtrar e exemplo

Usaria `proveniencia` e `precedencia`, `tema` e `status_vigencia`. O filtro é indispensável na pergunta sobre divergência entre o protocolo do hospital e a diretriz, pois é preciso recuperar as duas proveniências e dar prioridade ao protocolo local. Sem o filtro de `precedencia`, o sistema daria apenas a resposta de livro.

Metadados para citar e o que aparece na tela

Usaria `fonte`, `sociedade`, `secao` ou `recomendacao_ref`, `pagina`, `url_origem` e `data_vigencia`. Junto da resposta apareceria, por exemplo: Fonte, Surviving Sepsis Campaign 2021, seção Vasopressores, Recomendação 4.2, página 12, com link para o documento.

Metadado caro de acrescentar depois

Qualquer campo derivado por LLM ou do layout original, como a `recomendacao_ref` ou a `pagina`. Acrescentá-lo depois obriga a reprocessar e a gerar embeddings de toda a base de novo.

Como extrair esses metadados

De forma mista. `Tema`, `proveniencia`, `sociedade` e `precedencia` vêm da estrutura de pastas. `Datas`, `hash` e `página` vêm de regra. A `secao` e a `recomendacao_ref` vêm do LLM com saída estruturada em JSON schema.

Parte 5. Chunking

Estratégia e parâmetros

A estratégia é um recursive splitter consciente da estrutura da diretriz, quebrando por recomendação ou seção, sem cortar uma recomendação ao meio. O tamanho é de 300 a 500 tokens, pois uma recomendação clínica costuma ser curta e discreta, diferente do artigo de lei longo do cenário de imigração. O overlap é de 10 por cento. A unidade é a seção ou recomendação, com recuo para parágrafo. O splitter é recursivo. A estratégia varia por tipo de documento: diretriz por recomendação, protocolo interno por seção e tabela de dose tratada à parte como unidade atômica e enviada ao SQL.

Chunks pequenos, chunks grandes, tabela e imagem

Chunks muito pequenos perdem o contexto da recomendação, por exemplo a dose sem a condição do paciente a que se aplica. Chunks muito grandes estouram a janela do modelo de embedding e misturam duas condutas, o que dilui a similaridade. Uma tabela de dose é unidade atômica, não é cortada e vai para o SQL. Um fluxograma de conduta é mantido inteiro com descrição.

Como saber se o chunking foi bom

Por avaliação de recuperação com perguntas clínicas reais e a recomendação-fonte esperada, medindo a taxa de acerto no top-k. As evidências a reunir são: nenhuma dose foi separada da sua condição, a recomendação certa é recuperável inteira e nenhum chunk excede a janela do embedding.

Parte 6. Embeddings

Item	Resposta
Modelo escolhido	BioLORD-2023-M (FremyCompany/BioLORD-2023-M)
Dimensão do embedding	768
Suporta português?	Parcialmente. Não está entre os 7 idiomas oficiais, mas é compatível de forma não oficial pela destilação multilíngue
É multilíngue?	Sim. 7 idiomas europeus oficiais e mais de 50 compatíveis
Tamanho máximo de entrada	512 tokens
É open source?	Sim, disponível no HuggingFace
Pode ser executado localmente?	Sim, 278 milhões de parâmetros, roda em hardware modesto
Possui API?	Sim, por HuggingFace Inference e provedores terceiros
Custo aproximado	Gratuito para uso local, apenas custo de computação
Fonte	Remy et al. 2024 (JAMIA); model card HuggingFace FremyCompany/BioLORD-2023-M

Por que esse modelo é adequado ao cenário

O BioLORD-2023-M é especializado no domínio clínico e é apontado como o melhor modelo de embedding biomédico para similaridade de sentenças clínicas e representação de conceitos. Isso importa porque, na UTI, o modelo precisa entender que termos como clearance de creatinina, choque séptico, lactato e nomes de antibióticos são próximos no espaço clínico, o que um modelo de domínio geral pode não capturar. A janela de 512 tokens é suficiente aqui, pois os chunks são recomendações curtas, diferente do cenário de imigração, em que os artigos longos exigiram um modelo de contexto maior. O modelo é open source e roda localmente.

Modelo alternativo considerado e descartado

O BGE-M3, usado no cenário de imigração, é forte em português e tem contexto longo, mas é de domínio geral, sem a especialização biomédica. Foi mantido como alternativa de reserva, para o caso de o português das diretrizes da AMIB ter recuperação fraca no BioLORD. O MedEmbed, também clínico, foi descartado por ser centrado em inglês, com suporte fraco ao português.

Sigilo muda a escolha entre local e API?

Sim, mas de forma diferente do cenário de imigração. Aqui o corpus é público, pois são diretrizes publicadas, então gerar os embeddings do corpus por uma API seria aceitável. O

problema é a consulta, que carrega dado do paciente, como idade, creatinina e alergia, que é dado sensível de saúde. Por isso, rodar o modelo localmente para gerar o embedding da consulta protege o dado do paciente. A escolha local vale principalmente pela consulta, e não pelo corpus.

Relação entre a janela máxima e o chunking

A janela de 512 tokens do BioLORD é o teto do tamanho útil do chunk, e ela é suficiente porque a Parte 5 definiu chunks curtos por recomendação, de 300 a 500 tokens. Se o chunking fosse por seção longa, essa janela seria insuficiente e exigiria outro modelo. Escolher o embedding e o chunking foi uma decisão única, e neste cenário o chunk curto permitiu usar o modelo especializado de contexto menor.

Arquitetura final. Cenário 2

Diagrama do sistema (código Mermaid, renderizável em mermaid.live)

```
graph TD
    subgraph INGESTAO
        A[Diretrizes e protocolos PDF HTML DOCX] --> B{Roteador por tipo}
        B -->|PDF nativo| C[Docling para Markdown]
        B -->|tabela de dose| T[Extrai tabela para SQL]
        B -->|protocolo escaneado| D[OCR e Docling]
        C --> F[Limpeza, preserva dose e recomendacao]
        D --> F
        F --> G[Metadados: pasta e LLM em JSON]
        G --> H[Chunking por recomendacao]
        H --> I[Embeddings BioLORD-2023-M local]
        I --> J[(Banco vetorial FAISS com filtro de metadado)]
    end
    subgraph CONSULTA
        K[Medico: pergunta clinica] --> M{Roteador de intencao}
        M -->|dado do paciente| N[API do prontuario]
        M -->|valor de referencia| O[SQL]
        M -->|escore e dose| Pr[Regras deterministicas]
        M -->|conduta da diretriz| Q[Recuperacao RAG filtro vigente e precedencia]
        Q --> J
        N --> R[LLM: resposta ancorada e cita fonte]
        O --> R
        Pr --> R
        R --> S[Resposta com citacao e aviso: apoio, o medico decide]
```

Tabela de decisões

Etapas	Decisão	Justificativa em uma linha
Extração	Docling para Markdown, tabelas de dose enviadas à camada SQL	Diretriz é PDF nativo e a dose em tabela não pode ser achatada
Limpeza	Preservar dose, unidade e a estrutura de recomendação	Fundir condutas ou perder uma ressalva de dose afeta o paciente
Chunking	Recursive por recomendação, 300 a 500 tokens, overlap de 10 por cento	Recomendação clínica é curta e não pode ser cortada da sua condição
Metadados	Tema, proveniência e precedência, com vigência	Protocolo interno tem prioridade sobre a diretriz geral
Embeddings	BioLORD-2023-M local, 768 dimensões, 512 tokens	Domínio clínico especializado e chunk curto cabe na janela

Riscos e limitações da proposta

- Português não oficial no BioLORD-2023-M. A recuperação nas diretrizes em português da AMIB pode ser mais fraca. A mitigação é testar e usar o BGE-M3 como reserva se a taxa de acerto cair.
- Erro de extração de tabela de dose. Um valor trocado é grave, por isso a dose vai para a camada SQL e não para texto livre.
- Divergência entre diretriz e protocolo interno. Se a precedência estiver errada, o sistema pode dar a conduta que não vale naquele hospital.
- Cálculo de dose e de escore. Depende da camada de regras, o que faz do roteador de intenção um ponto sensível.
- Não substitui o julgamento clínico. O sistema é de apoio, e o aviso reduz, mas não anula, o risco de excesso de confiança.

Comparação entre os dois cenários

Em que pontos as decisões foram diferentes e por quê

As diferenças vêm do perfil do usuário, da criticidade do erro, da língua e da natureza do documento, e cada uma puxou uma decisão técnica distinta.

O modelo de embedding foi a diferença mais visível. O Cenário 1 usa o BGE-M3, escolhido pela cobertura multilíngue ampla e pela janela de 8192 tokens, porque o usuário pergunta em várias línguas e os artigos de lei são longos. O Cenário 2 usa o BioLORD-2023-M, escolhido pela especialização em vocabulário clínico, porque o valor está em entender termos médicos, e a janela de 512 tokens basta, já que a recomendação é curta.

O tamanho do chunk seguiu essa mesma lógica e ficou diferente. No Cenário 1, o chunk é maior, de 500 a 800 tokens, para conter um artigo inteiro. No Cenário 2, o chunk é menor, de 300 a 500 tokens, porque a unidade é uma recomendação clínica curta.

A frequência de ingestão também mudou. O Cenário 1 exige verificação semanal, com picos em crise, porque a norma muda rápido e em rajadas. O Cenário 2 aceita verificação mensal, porque diretriz nova é rara.

O tratamento do sigilo divergiu num ponto fino. No Cenário 1, o dado é sensível na origem e na consulta, o que obriga o modelo local em todo o fluxo. No Cenário 2, o corpus é público e apenas a consulta carrega dado do paciente, então o modelo local se justifica principalmente pela consulta.

O eixo de filtro central também é diferente. No Cenário 1, o filtro decisivo é a jurisdição, para não misturar regras de regiões diferentes. No Cenário 2, o filtro decisivo é a precedência, para o protocolo interno do hospital ter prioridade sobre a diretriz geral.

Em que pontos as decisões foram iguais e se isso é boa prática

Vários pontos ficaram iguais, e isso é boa prática geral, não repetição automática, porque cada um resolve um problema que os dois cenários realmente têm em comum.

A natureza híbrida foi mantida nos dois. Ambos usam um roteador de intenção que envia cálculo e dado exato para regras, SQL ou API, e deixa para o RAG apenas o que é interpretação de texto. Isso se repete porque os dois cenários misturam pergunta de texto com pergunta de fato, e forçar o RAG a calcular seria errado em ambos.

O controle de vigência por metadado também é igual nos dois. Ambos marcam a versão antiga como revogada e filtram por vigente. Isso se repete porque os dois sofrem do mesmo risco, que é responder pela versão desatualizada, seja a lei de 2024 ou uma diretriz superada.

A exigência de citação da fonte é comum aos dois, porque nos dois o usuário só confia na resposta se puder ver de onde ela veio, seja o mediador da ONG ou o médico.

A extração com Docling, a limpeza conservadora na estrutura e o splitter recursivo consciente da estrutura se repetem porque ambos partem de documentos formais e organizados em seções, e preservar essa estrutura é o que garante a citação nos dois.

A diferença entre boa prática e repetição sem pensar está em conseguir justificar cada ponto igual a partir de uma dor comum aos dois cenários. Onde a dor era a mesma, a decisão foi a mesma. Onde a dor mudou, a decisão mudou. Por isso a igualdade aqui é sinal de um padrão de projeto sólido, e não de cópia.

Se tivesse que construir apenas um dos dois, qual escolheria e por quê

Escolheria o Cenário 1, o assistente de direitos para imigrantes, por três razões.

A primeira é o impacto social. O sistema atende diretamente a pessoas em situação de vulnerabilidade, que perdem direitos por não entender a informação, enquanto o Cenário 2 apoia um profissional que já tem formação e outras fontes de consulta.

A segunda é a adequação ao RAG. O Cenário 1 tem a combinação mais forte de barreira de linguagem, norma que muda rápido e documento privado local, que são exatamente as condições em que RAG entrega mais valor do que um LLM sozinho.

A terceira é o risco controlável. No Cenário 2, o erro afeta a segurança física do paciente, o que exige validação clínica rigorosa e coloca o projeto num terreno de responsabilidade alta. No Cenário 1, o erro também custa um direito, mas o desenho com citação da fonte e encaminhamento a atendimento humano permite construir e demonstrar o sistema com segurança, sem depender de aprovação médica.

Vale registrar que o Cenário 2 é o mais crítico e o mais exigente em precisão, e por isso serve de bom contraste. Para construir e mostrar um sistema completo e de impacto, porém, o Cenário 1 é a escolha.

Referências

- Boletín Oficial del Estado (BOE) e Ley de Extranjería. <https://www.boe.es>
- Espanha finaliza medida de regularização para até 500 mil imigrantes. Euronews, 2026.
<https://www.euronews.com/my-europe/2026/04/14/spain-finalises-amnesty-measures-to-give-legal-status-to-up-to-500000-immigrants>
- Espanha aprova regularização em massa de imigrantes sem documentos, veja as regras. Jornal Passaporte, 2026.
<https://www.jornalpassaporte.com.br/2026/04/15/espanha-aprova-regularizacao-em-massa-de-imigrantes-sem-documentos-veja-as-regras/>
- Ceuta busca a transferência de menores desacompanhados após entrada em massa. Reuters via US News, 2026.
<https://www.usnews.com/news/world/articles/2026-08-05/spains-ceuta-seeks-transfer-of-unaccompanied-migrant-minors-to-mainland-spain-after-border-rush>
- Ceuta, preocupação com menores desacompanhados. InfoMigrants, 2026.
<https://www.infomigrants.net/en/post/72937/ceuta-concern-over-unaccompanied-minors-and-young-people>
- Espanha adota medidas para mover menores desacompanhados das Canárias (reforma do Artigo 35). Euronews, 2025.

<https://www.euronews.com/my-europe/2025/03/19/spain-adopts-measures-to-move-lo-ne-migrant-minors-away-from-canary-islands>

- BGE-M3, model card. HuggingFace, BAAI. <https://huggingface.co/BAAI/bge-m3>
- Chen et al., 2024. BGE M3-Embedding. arXiv. <https://arxiv.org/abs/2402.03216>
- Guia de modelos de embedding open source. BentoML. <https://www.bentoml.com/blog/a-guide-to-open-source-embedding-models>
- Remy, F., Demuynck, K., Demeester, T., 2024. BioLORD-2023: semantic textual representations fusing large language models and clinical knowledge graph insights. JAMIA. <https://doi.org/10.1093/jamia/ocae029>
- BioLORD-2023-M, model card. HuggingFace, FremyCompany. <https://huggingface.co/FremyCompany/BioLORD-2023-M>
- MedEmbed, modelos de embedding para recuperação clínica. HuggingFace, abhinand. <https://huggingface.co/blog/abhinand/medembed-finetuned-embedding-models-for-medical-ir>
- Surviving Sepsis Campaign, diretriz internacional de sepse. Intensive Care Medicine, 2021.
- Associação de Medicina Intensiva Brasileira (AMIB), diretrizes e consensos. <https://www.amib.org.br>
- Ferramentas usadas no projeto: Docling, LangChain, sentence-transformers e FAISS.

Uso de inteligência artificial na atividade

Usei o assistente Claude, da Anthropic, para apoiar o trabalho em três frentes: organizar a estrutura do pipeline, discutir e criticar a escolha dos cenários, e pesquisar fatos atuais com a ferramenta de busca na web do assistente, como as regras da regularização espanhola de 2026, os números da crise de Ceuta e as especificações do modelo BGE-M3.

A verificação foi feita conferindo cada dado técnico e factual nas fontes primárias listadas nas referências, como o model card oficial do BGE-M3, o artigo dos autores e os portais de notícia e órgãos oficiais. A escolha do cenário, as decisões de arquitetura e as justificativas partiram da minha própria experiência na residência, das atividades AULA_01 a AULA_05 e da minha formação.